

Student No ;71701268

CNS account : s17126su

Name : 有働 峻介

#Pythonで進めました

#Python3 環境..JupyterLab

```
import pandas as pd
```

```
from urllib import request
```

```
from bs4 import BeautifulSoup
```

```
import numpy as np
```

#課題1

#下記のテーブル内容を取得し、「URL」を引数にとりテーブルをデータフレームとして出力する関数を作成して下さい。(コードを貼って下さい)

```
def scrR(url):
```

```
    html = request.urlopen(url)
```

```
    soup = BeautifulSoup(html, 'html.parser')
```

```
    td = soup.findAll("td")
```

```
    th = soup.findAll("th")
```

```
    th_s = []
```

```
    td_s = []
```

```
    for i in range(len(th)):
```

```
        th_s.append(th[i].string)
```

```
    for i in range(len(td)):
```

```
        td_s.append(td[i].string)
```

```
    td_s = np.reshape(td_s, (120, 45)) # ここまだ一般化できる余地あり
```

```
    return pd.DataFrame(td_s, columns = th_s)
```

```
df = scrR("http://web.sfc.keio.ac.jp/~sk/ynl-r-homework.html")
```

#課題 2

#課題 1 で出力されたデータフレームを 「日時」「天気」「気温」「アトラクション名」「待ち時間」

#の 5 つのカラムで構成されるデータフレームに変換して下さい。(コードを貼って下さい)

```
df_2 = scrR("http://web.sfc.keio.ac.jp/~sk/ynl-r-homework.html")
```

```
df_changed = df_2[df_2.columns[3:45]]
```

#アトラクション名が入った配列を作成

```
atractions = []
```

```
for i in range(42):
```

```
    atr = [df_2.columns[i + 3]]*120
```

```
    atractions.extend(atr)
```

```
    #長さ 120*42 ね
```

#待ち時間が入った配列を作成

```
wait = []
```

```
for i in range(42):
```

```
    con = df_changed[df_changed.columns[i]]
```

```
    wait.extend(con)
```

#いらんとこ削除

```
for i in range(42):
```

```
    del df_2[df_2.columns[3]]
```

```

#attractions[], wait[]と合うように df の長さを調節
df_a = df_2

for i in range(41):
    df_2 = df_2.append(df_a)

#アトラクション名と待ち時間の配列を concat() 使って元の df とくっつける
#元の df じゃないやいらんとこ削除したやつや
df_2["アトラクション名"] = attractions
df_2["待ち時間"] = wait
#課題 3
#「ジャングルクルーズ」「プーさんのハニーハント」「ミニーの家」の待ち
時間のヒストグラムを作図して下さい。
#なお、平均と 1SD 値に補助線も引いて下さい。
#そもそも、、、度数・階級
#階級...今回は待ち時間

# なんか半透明に 3 つ並べてグラフを作れるらしいから余力あったらそれも試
そう

# 4. ジャングルクルーズ
# 14. プーさんのハニーハント
# 29. ミニーの家

import matplotlib.pyplot as plt

df_3 = scrR("http://web.sfc.keio.ac.jp/~sk/ynl-r-homework.html")

# 行/列指定でアトラクション別の待ち時間の値を引っ張ってくる
atr_jun = df_3["4. ジャングルクルーズ"].values

```

```
atr_pooh = df_3[" 1 4. プーさんのハニーハント"].values
atr_minnie = df_3[" 2 9. ミニーの家"].values
```

```
# ndarray のままだと hist() との互換性がよろしくないなので list に直します
atr_jun = atr_jun.tolist()
atr_pooh = atr_pooh.tolist()
atr_minnie = atr_minnie.tolist()
```

```
# よくわからない点...5分待ちがうまく表示されない。
# list の中が全部文字列だったから数値に直します
# 補助線引く観点でもこっちのがいいや
atr_jun = [0 if n == '-' else int(n) for n in atr_jun]
atr_pooh = [0 if n == '-' else int(n) for n in atr_pooh]
atr_minnie = [0 if n == '-' else int(n) for n in atr_minnie]
```

```
# 平均値、1SD 値をセット
jun_mean = np.mean(atr_jun)
pooh_mean = np.mean(atr_pooh)
minnie_mean = np.mean(atr_minnie)
```

```
jun_1sd = jun_mean + np.std(atr_jun)
pooh_1sd = pooh_mean + np.std(atr_pooh)
minnie_1sd = minnie_mean + np.std(atr_minnie)
```

```
# figure をセット
fig_jun = plt.figure().add_subplot(1, 1, 1)
fig_pooh = plt.figure().add_subplot(1, 1, 1)
fig_minnie = plt.figure().add_subplot(1, 1, 1)
```

```
# ジャングルクルーズ
```

```
fig_jun.hist(atr_jun, bins=20, color="green")
fig_jun.set_title('Jungle Cruise')
fig_jun.set_xlabel('wait-time')
fig_jun.set_ylabel('freq')
fig_jun.set_ylim([0, 40])
fig_jun.vlines(x=jun_mean, ymin=0, ymax=30, label="mean")
fig_jun.vlines(x=jun_1sd, ymin=0, ymax=30, color="skyblue",
label="1sd")
fig_jun.legend(loc='upper right')
```

```
# プーさんのハニーハント
```

```
fig_pooh.hist(atr_pooh, bins=20, color="yellow")
fig_pooh.set_title("Pooh's Hunny Hunt")
fig_pooh.set_xlabel('wait-time')
fig_pooh.set_ylabel('freq')
fig_pooh.set_ylim([0, 40])
fig_pooh.vlines(x=pooh_mean, ymin=0, ymax=30, label="mean")
fig_pooh.vlines(x=pooh_1sd, ymin=0, ymax=30, color="skyblue",
label="1sd")
fig_pooh.legend(loc='upper right')
```

```
# ミニーの家 これが度数の最大値を取ったので比較しやすいように他もそれ
に合わせる (40)
```

```
fig_minnie.hist(atr_minnie, bins=20, color="red")
fig_minnie.set_title("Minnie's House")
fig_minnie.set_xlabel('wait-time')
fig_minnie.set_ylabel('freq')
fig_minnie.vlines(x=minnie_mean, ymin=0, ymax=30, label="mean")
```

```
fig_minnie.vlines(x=minnie_1sd, ymin=0, ymax=30, color="skyblue",
label="1sd")
fig_minnie.legend(loc='upper right')
```


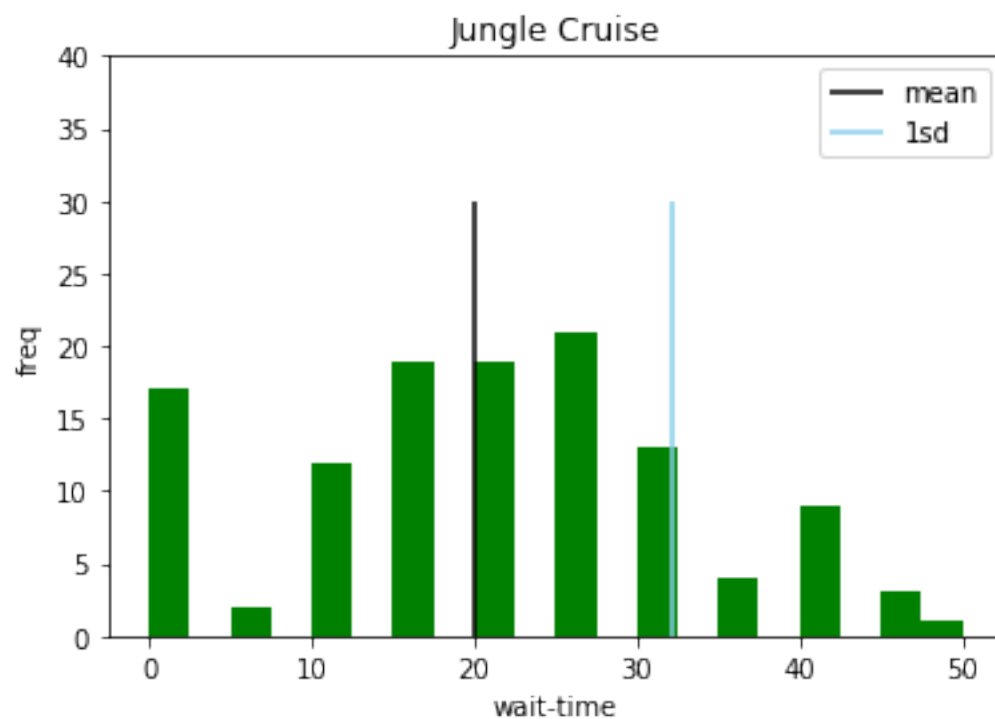
全部のやつ (いちばん直感的に見れるのかな)

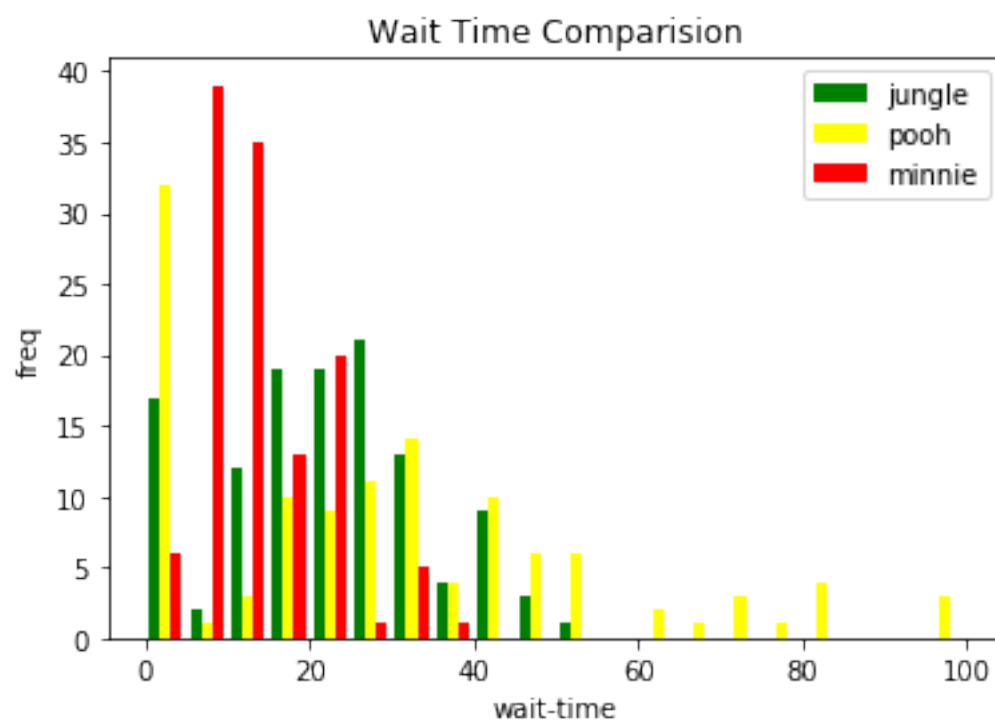
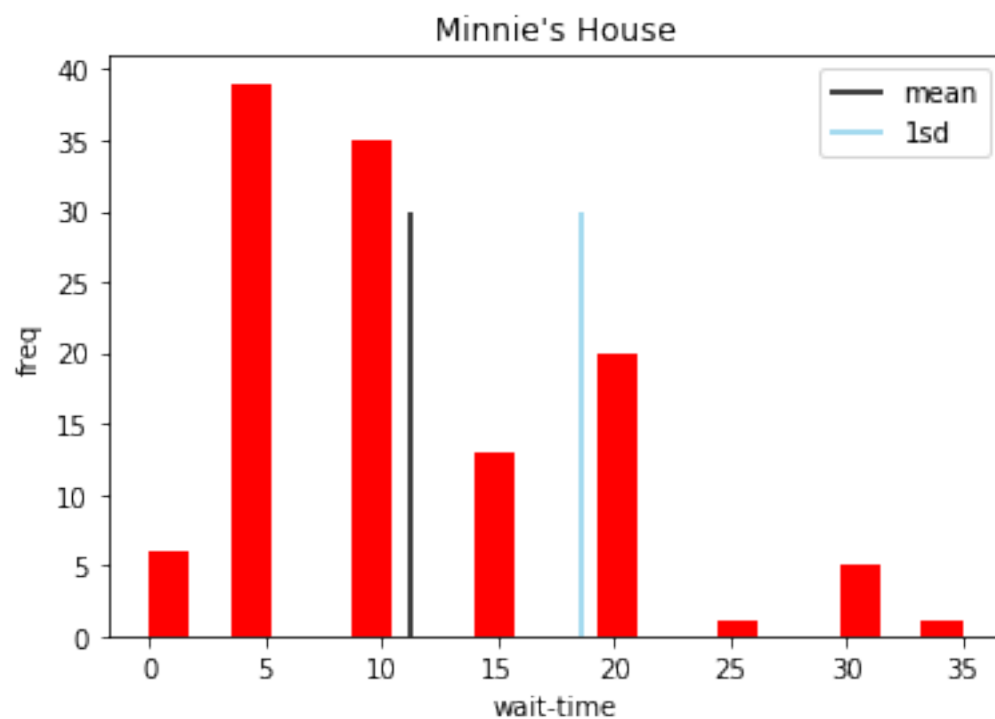
```
fig_all = plt.figure().add_subplot(1, 1, 1)
fig_all.hist([atr_jun, atr_pooh, atr_minnie], bins=20, color=['green',
'yellow', 'red'], label=['jungle', 'pooh', 'minnie'])
fig_all.legend(loc='upper right')
fig_all.set_title("Wait Time Comparision")
fig_all.set_xlabel('wait-time')
fig_all.set_ylabel('freq')
```

この後のために関数化したいなあ

```
def graphize(atr_name):
```

```
    df = scrR("http://web.sfc.keio.ac.jp/~sk/ynl-r-homework.html")
    atr = df[atr_name].values
    atr = atr.tolist()
    atr = [0 if n == '-' else int(n) for n in atr]
    fig = plt.figure().add_subplot(1, 1, 1)
    fig.hist(atr, bins=20, color="green")
```





#課題 4. 「ビッグサンダーマウンテン」の待ち時間を予測する重回帰モデルを作成し、5月26日の待ち時間を予測して下さい。

#なお、予測に用いた説明変数も理由と共に明記して下さい。 5月26日は気温：22.8、晴です。

```
from sklearn import linear_model
```

```
def multi_re(ob_tmp, ob_clm, atr_name):
```

```
    cls = linear_model.LinearRegression()
```

```
    df_4 = scrR("http://web.sfc.keio.ac.jp/~sk/ynl-r-homework.html")
```

```
    if ob_clm == "晴":
```

```
        ob_clm_int = 1
```

```
    elif ob_clm == "曇":
```

```
        ob_clm_int = 2
```

```
    elif ob_clm == "小":
```

```
        ob_clm_int = 3
```

```
    elif ob_clm == "雨":
```

```
        ob_clm_int = 4
```

```
    else:
```

```
        ob_clm_int = 0
```

```
    # 説明変数に気温と天気を使用
```

時間帯/日付（曜日）も説明変数に含むアルゴリズムの構築を試みた
が、アイデア、技術力が追いつかず今回は断念。
配列（特に DataFrame, Series）についての深い考察、知識武装を行い
再挑戦する見込み。

```
tmp = df_4.loc[:, ['気温']].as_matrix()
tmp[119] = 0
```

```
for n in range(len(tmp)):
    tmp[n] = float(tmp[n])
```

```
clm = df_4.loc[:, ["天気"]].as_matrix()
# 天気を数値化
for i in range(len(clm)):
    if clm[i] == "晴":
        clm[i] = 1
    elif clm[i] == "曇":
        clm[i] = 2
    elif clm[i] == "小":
        clm[i] = 3
    elif clm[i] == "雨":
        clm[i] = 4
    else:
        clm[i] = 0
```

```

# 目的変数に待ち時間を使用
atr = df_4[atr_name].as_matrix()
atr = [0 if n == '-' else int(n) for n in atr]

var = np.hstack([tmp, clm])

cls.fit(var, atr)

coef = cls.coef_
intercept = cls.intercept_

atr_wait = coef[0]*ob_tmp + coef[1]*ob_clm_int + intercept
print("気温:" + str(ob_tmp) + " 天気:" + str(ob_clm) + " " +
atr_name + "の予測待ち時間は" + str(atr_wait))

multi_re(ob_tmp=22.8, ob_clm="晴", atr_name="7. ビッグサンダー・マウン
テン")

気温:22.8 天気:晴 7. ビッグサンダー・マウンテンの予測待ち時間は
76.74172321039022

#課題 5. 5/26 15:30 に乗るべきアトラクションは何ですか？乗るべきでない
アトラクションは何ですか？

df_5 = scrR("http://web.sfc.keio.ac.jp/~sk/ynl-r-homework.html")

# それぞれで分析、待ち時間を算出。その後最低のものを選択

```

```
for i in range(42):  
    multi_re(ob_tmp=22.8, ob_clm="晴", atr_name=df_5.columns[i + 3])
```

#下記の解析結果より

#5. スイスファイミリーツリーハウス

#28. ドナルドのボート

#35. グランドサーキット・レースウェイ

#38. エントランスグリ（ベビーカー、車椅子レンタル側）

#上記4アトラクションが最短で乗ることができる。故に乗るべきである。

#12. スプラッシュ・マウンテン の待ち時間が最長で約120分。故に乗るべきでない。

気温:22.8 天気:晴 1. オムニバスの予測待ち時間は1.5092550414067367

気温:22.8 天気:晴 2. ウェスタンリバー鉄道の予測待ち時間は

24.010018501595063

気温:22.8 天気:晴 3. カリブの海賊の予測待ち時間は21.364106319163618

気温:22.8 天気:晴 4. ジャングルクルーズの予測待ち時間は

20.012869403874497

気温:22.8 天気:晴 5. スイスファイミリーツリーハウスの予測待ち時間は0.0

気温:22.8 天気:晴 6. 魅惑のチキルーム:スティッチ・プレゼンツアロハ・

エ・コモ・マイ!の予測待ち時間は9.120071628974273

気温:22.8 天気:晴 7. ビッグサンダー・マウンテンの予測待ち時間は

76.74172321039022

気温:22.8 天気:晴 8. ウェスタンランド・シューティングギャラリーの予測

待ち時間は14.50200765265109

気温:22.8 天気:晴 9. カントリーベア・シアターの予測待ち時間は

4.800329979343313

気温:22.8 天気:晴 10. トムソーヤ島いかだの予測待ち時間は
4.806764047086098

気温:22.8 天気:晴 11. 蒸気船マークトウェイン号の予測待ち時間は
8.414250892224995

気温:22.8 天気:晴 12. スプラッシュ・マウンテンの予測待ち時間は
120.19420461590511

気温:22.8 天気:晴 13. ビーバーブラザーズのカヌー探険の予測待ち時間は
27.49143442746109

気温:22.8 天気:晴 14. プーさんのハニーハントの予測待ち時間は
44.75774267344663

気温:22.8 天気:晴 15. ホーンテッドマンションの予測待ち時間は
64.05533616187319

気温:22.8 天気:晴 16. アリスのティーパーティーの予測待ち時間は
43.903970618753604

気温:22.8 天気:晴 17. イッツ・ア・スモールワールドの予測待ち時間は
12.611765146728349

気温:22.8 天気:晴 18. キャッスルカルーセルの予測待ち時間は
17.212195631601176

気温:22.8 天気:晴 19. シンデレラのフェアリーテイル・ホールの予測待ち
時間は 24.762058121401296

気温:22.8 天気:晴 20. ピノキオの冒険旅行の予測待ち時間は
20.46554050942258

気温:22.8 天気:晴 21. ピーターパン空の旅の予測待ち時間は
38.40050292387835

気温:22.8 天気:晴 22. ミッキーのフィルハーマジックの予測待ち時間は
16.256340370538872

気温:22.8 天気:晴 23. 白雪姫と七人のこびとの予測待ち時間は
24.688282799767464

気温:22.8 天気:晴 24. 空飛ぶダンボの予測待ち時間は 40.24123353825321

気温:22.8 天気:晴 25. ガジェットのゴーコースターの予測待ち時間は
20.290737366279956

気温:22.8 天気:晴 26. グーフィーのペイント&プレイハウスの予測待ち時間は 17.383993819255

気温:22.8 天気:晴 27. チップとデールのツリーハウスの予測待ち時間は 0.10656957362000927

気温:22.8 天気:晴 28. ドナルドのボートの予測待ち時間は 0.0

気温:22.8 天気:晴 29. ミニーの家の予測待ち時間は 15.85883163076532

気温:22.8 天気:晴 30. ロジャーラビットのカートゥーンスピンの予測待ち時間は 32.46964245990076

気温:22.8 天気:晴 31. スター・ツアーズ:ザ・アドベンチャーズ・コンティニューの予測待ち時間は 27.08201070169717

気温:22.8 天気:晴 32. スペース・マウンテンの予測待ち時間は 42.719729291178666

気温:22.8 天気:晴 33. バズライトイヤーのアストロブラスターの予測待ち時間は 59.53339154464419

気温:22.8 天気:晴 34. モンスターズ・インク “ライド&ゴーシーク!” の予測待ち時間は 62.0923792078419

気温:22.8 天気:晴 35. グランドサーキット・レースウェイの予測待ち時間は 0.0

気温:22.8 天気:晴 36. スタージェットの予測待ち時間は 2.9373331379395786

気温:22.8 天気:晴 37. ステッチ・エンカウンター (キャプテンEO・ミクロアドベンチャー!) の予測待ち時間は 24.448714248572983

気温:22.8 天気:晴 38. エントランスグリ (ベビーカー、車椅子レンタル側) の予測待ち時間は 0.0

気温:22.8 天気:晴 39. エントランスグリ (メインストリート・ハウス側) の予測待ち時間は 0.3381799255417409

気温:22.8 天気:晴 40. ウッドチャック・グリーティングトレイル (デイジー) の予測待ち時間は 41.37391010477071

気温:22.8 天気:晴 41. ウッドチャック・グリーティングトレイル (ドナルド) の予測待ち時間は 70.67796720555279

気温:22.8 天気:晴 42. ミッキーの家とミート・ミッキーの予測待ち時間は 69.04453021922617

